

Inteligência Artificial - Prof. Fábio Rezende de Souza

**COMPARATIVO DE EFICIÊNCIA EM LLMS OPEN-
SOURCE: GEMMA 2B X MISTRAL 7B**

Fábio Stampone Miranda

Rafael Souza de Mello


Pedro Alves de Matos

O problema

Escolher o Modelo de Linguagem Grande (LLM) correto envolve um trade-off (troca) entre custo computacional e qualidade da resposta.

Objetivo


Analisar se modelos menores (2 Bilhões de parâmetros) conseguem competir com modelos médios (7 Bilhões) em tarefas de raciocínio e geração de código, utilizando hardware acessível (Google Colab T4 GPU).



Solução Desenvolvida

- Tecnologias: Python, Hugging Face Transformers, PyTorch e BitsAndBytes (para quantização de 4-bits).
- Metodologia:
 - Execução de inferência sequencial em ambiente controlado.
 - Modelos: google/gemma-2b-it (Leve/Mobile) vs. mistralai/Mistral-7B-Instruct (Performance).
 - Métricas: Tempo de inferência (latência) e Coerência qualitativa da resposta.
- Código:

O script utiliza a biblioteca transformers para carregar os modelos dinamicamente e medir o tempo exato de geração de tokens para prompts técnicos (SQL, Python).



Resultados Observados

- Gemma 2B: Extremamente rápido, ideal para respostas curtas, mas com menor profundidade de raciocínio.
- Mistral 7B: Mais lento devido ao tamanho, porém com respostas mais completas e melhor estruturação de código.

=== RESULTADOS DA COMPARAÇÃO ===				
	Modelo	Prompt	Tempo (s)	Resposta Gerada
0	google/gemma-2b-it	Explique o conceito de 'Recursividade' em Pyth...	2.92	A frase "O que é recursivo em Python é quando ...
1	google/gemma-2b-it	Crie uma função simples em SQL para calcular a...	5.28	```sql\nSELECT AVG(venda) FROM tabela_de_venda...
2	google/gemma-2b-it	Qual é a capital da França? Responda apenas co...	1.63	A capital da França é Paris. É a maior cidade ...
3	mistralai/Mistral-7B-Instruct-v0.2	Explique o conceito de 'Recursividade' em Pyth...	9.77	Recursividade em Python é uma técnica de progr...
4	mistralai/Mistral-7B-Instruct-v0.2	Crie uma função simples em SQL para calcular a...	9.28	I'm an AI language model and I don't have the ...
5	mistralai/Mistral-7B-Instruct-v0.2	Qual é a capital da França? Responda apenas co...	2.46	Paris\n\nI'm an assistant designed to help ans...

Para aplicações em tempo real ou dispositivos móveis (Edge AI), o Gemma 2B é superior. Para assistentes de codificação ou análise complexa rodando em servidor, o Mistral 7B justifica o custo extra de processamento.

